

Анализ текстов

Методы искусственного интеллекта

Лекция 8

Обработка текстов на естественном языке (NLP)

Обработка текстов на естественном языке (natural language processing, NLP) – направление развития искусственного интеллекта и компьютерной лингвистики с целью разработки методов для понимания смысла текста и генерации грамотного текста.

Популярные задачи:

- Аннотирование и реферирование текстов.
- Проверка правописания.
- Машинный перевод.
- Понимание текста.
- Генерация текста.
- Вопросно-ответные системы.

История развития NLP

1950 – начало 1990. Символьный NLP.

1990 – наст. вр. Статистический NLP.

2015 – наст. вр. Нейросетевой подход.

Символьный NLP анализ текста на основе правил, которые были созданы вручную.

Статистический NLP:

- правила извлекаются в процессе анализа текстов;
- показывают приемлемый уровень качества на текстах с незнакомыми словами и/или структурой;
- повышение качества достигается увеличением сложности модели.

Нейросетевые методы позволяют учитывать смысл текстов на основе векторного представления слов (эмбедингов) и не требуют дополнительных этапов анализа.

Базовые этапы NLP

1. Графематический анализ (токенизация, выделение элементов текста: ФИО, адреса, ссылки, работа с элементами языка разметки и т. д.).
2. Статистический анализ (мешок слов, частотный портрет).
3. Морфологический анализ (стемминг, лемматизация, определение частей речи).
4. Синтаксический анализ (построение дерева зависимостей).
5. Семантический анализ (выделение объектов, свойства объектов, связей между объектами).

Анализ текстов

Анализ текстов (интеллектуальный анализ текстов, text mining) – область применения методов интеллектуального анализа данных для извлечения скрытых закономерностей из неструктурированных/слабоструктурированных текстовых данных.

В чем разница между Text Mining и NLP?

1. NLP определяет смысл текста, ТМ пытается выявить скрытые закономерности.
2. ТМ направлен на подготовку данных для дальнейшего анализа.
3. ТМ не требует этапа семантического анализа для решения задачи.
4. ТМ направлен на анализ множества документов.
5. ТМ основан на анализе слов и их частоты встречаемости.
6. ТМ в меньшей степени зависит от особенностей и типа языка.
7. ТМ в меньшей степени ориентирован на учет контекста.

Предобработка текста

Предобработка текста является важным этапом, на котором решаются следующие задачи:

1. Трансформация.
2. Токенизация.
3. Выделение частей речи (POS tagging).
4. Нормализация.
5. Фильтрация.

Трансформация и токенизация текста

Этап трансформации направлен на:

- приведение регистра символов к общему параметру;
- удаление символов, которые не описывают содержимое документа;
- преобразование не текстовых элементов в текст;
- преобразование спец. символов языка к ascii аналогам (при возможности);
- добавление дополнительных сведений к словам (почтовый адрес или телефон);
- объединение ФИО в одну структурную единицу;
- и т. д.

Этап токенизации направлен на разделение текста на отдельные структурные элементы.

К выделенным структурным элементам будут применяться следующие этапы предобработки текста.

Выделение частей речи (POS tagging)

Выделение частей речи является частью этапа морфологического анализа.

На данном этапе каждому слову текста ставится в соответствие множество морфологических признаков, которые зависят от роли слова в предложении:

- часть речи,
- падеж,
- род,
- число,
- одушевленность,
- и др.

Нормализация

Нормализация позволяет свести слова, представленные в разной форме, к одной форме.

Для нормализации обычно используют один из двух методов:

- стемминг: удаление окончаний и/или суффиксов;
- лемматизация: приведение слова к словарной форме (ед. число, именительный падеж).

стол, столы, столов => стол

Стемминг работает на уровне алгоритмов и не зависит от языка.

Лемматизация работает на основе подготовленных словарей, зависит от качества словаря, разрабатывается для каждого языка в отдельности.

Фильтрация

На этапе фильтрации происходит сокращение пространства признаков за счет удаления слов.

Слова удаляются на основе:

1. Словаря стоп-слов.
2. Частотного распределения.
3. Длины слова.
4. Регулярных выражений.

Также на этапе фильтрации можно использовать различные методы машинного обучения и статистического анализа для определения шумов, шаблонных фраз и т. д. с целью их удаления.

Создание N-грамм

Этап создания N-грамм следует выполнять после этапов предобработки текста.

N-граммы позволяют сгруппировать слова текста по их взаимному расположению.

Обычно используют:

- биграммы ($n = 2$),
- триграммы ($n = 3$),
- 4-граммы,
- 5-граммы.

Биграммы для текста «мама мыла раму мылом»: мама мыла, мыла раму, раму мылом.

Триграммы: мама мыла раму, мыла раму мылом.

Индексирование текста

На этапе индексирования происходит векторизация текстов (кодирование).

Выделяют несколько способов индексирования:

1. Мешок слов (Bag of words, BoW).
2. Частотный портрет (Term frequency).

Для построения мешка слов необходимо:

1. Выделить словарь слов для всех документов. Множество всех слов из всех документов без повторений.
2. Посчитать количество встречаемости слова из словаря в текущем документе.

Результат:

мама	мыла	раму	мылом
1	1	1	1

Частотный портрет

$$\text{tfidf} = \text{tf} \times \text{idf} \times n$$

Алгоритм получения частотного портрета основан на мешке слов, но с добавлением двух дополнительных компонентов:

1. Обратная документная частота.
2. Нормализация.

Методы расчета tf:

- количество слов в документе (мешок слов),
- бинарный признак,
- логарифмическая шкала ($\log(\text{tf}) + 1$) и др.

Методы нормализации:

- без нормализации ($= 1$),
- $1 / \sqrt{\text{tf}_1 + \text{tf}_2 + \text{tf}_3 + \dots}$ и др.

Методы расчета idf:

- без расчета ($= 1$),
- $\log(N+1 / |d: t \in d| + 1)$ и др.

мама	мыла	раму	мылом
0.16	0.19	0.11	0.16

Эмбединги

Векторное представление слов (эмбединги) – метод сопоставления словам некоторого уникального числового вектора.

Векторы формируются на основе дистрибутивной семантики.

Дистрибутивная семантика вычисляет степень семантической (смысловой) близости между словами на основе их распределения (дистрибуции) в большом количестве текстовых документов с учетом контекста.

Для получения эмбедингов могут быть использованы: Word2Vec, FastText, BERT и др.

мама	мыла	раму	мылом
6.628802299499512	5.679202556610107	6.117740154266357	5.738062381744385

Синтаксический анализ

Синтаксический анализ используется для построения синтаксического дерева на основе анализа морфологических признаков слов текста.

Синтаксическое дерево позволяет получить зависимости между словами и их морфологические свойства.


Мама | nsubj | мыла | NOUN []

мыла | ROOT | мыла | NOUN ['Мама', 'раму', 'мылом', '.']

раму | obj | мыла | NOUN []

мылом | iobj | мыла | NOUN []

. | punct | мыла | NOUN []



Извлечение именованных сущностей

Извлечение именованных сущностей (Named entity recognition, NER) – подзадача процесса извлечения информации из текста, в процессе которой происходит поиск имен людей, географических названий, названий мест и т. д.

Мама, Анна Ивановна, мыла раму мылом в Москве.

Мама, Анна Ивановна PER, мыла раму мылом в Москве LOC.

Проблемы анализа текстов

Основные проблемы анализа текстов:

1. Многие инструменты для анализа текстов не работают с русским языком.
2. Многие инструменты для анализа текстов плохо работают с русским языком.
3. Для анализа текстов следует иметь базовые знания в лингвистике.
4. Многие NLP задачи можно решить только с применением глубокого обучения или других сложных моделей.
5. Иногда требуется собрать очень большой набор документов для получения приемлемого уровня качества.
6. Иногда требуется формирование баз и графов знаний для повышения качества анализа (но это совсем другая история).

Преимущества и недостатки статистических методов

Преимущества:

1. Набор данных собирается достаточно просто (в большинстве случаев).
2. Высокая скорость работы, приемлемый уровень качества.
3. Можно решать задачи методами машинного обучения с учителем и без учителя.

Недостатки:

1. Возможность решения простых задач.

Формальная постановка задачи анализа текстов

Требования к данным:

1. Имеется понимание задачи.
2. Имеется понимание способов решения задачи.
3. Имеется достаточное количество данных.

Гиперпараметры:

1. Методы предобработки текста.
2. Методы индексирования текста.
3. Методы машинного обучения.

Оценка и улучшение качества нечеткой системы

В зависимости от класса решаемой задачи могут быть использованы метрики для оценки качества моделей машинного обучения:

1. Классификация.
2. Кластеризация.

Выводы и рекомендации

1. Задача анализа текстов состоит в выборе оптимальных способов предобработки и индексирования документов.
2. Text mining позволяет структурировать текст для дальнейшего анализа и выявления скрытых закономерностей.
3. Выбор методов предобработки текста влияет на количество признаков (размер пространства признаков), что может привести к значительному повышению потребления ресурсов и времени анализа.
4. Необходимо найти баланс между информативными и неинформативными словами текста.
5. Выбор метода индексирования текста влияет на полученный вектор, что влияет на результаты анализа (влияние/вес признаков).
6. В качестве методов анализа можно использовать методы машинного обучения с учителем и без учителя.