

Машинное обучение

Сбор и подготовка данных

Методы искусственного интеллекта

Лекция 2


Машинное обучение

Машинное обучение – процесс решения некоторой задачи путем построения *статистической модели* на основе анализа некоторого *набора данных*.

Набор данных должен иметь минимально подходящий для решения задачи объем и содержать наблюдения о некотором объекте (сущности).


Наблюдения представляют собой некоторое множество значений показателей (атрибутов) объекта.

Аппроксимировать — это заменить одни результаты другими, близкими к исходным, но упрощенными.



Типы машинного обучения

1. *Обучение с учителем.* Обучить модель повторять `someFunc()` для `Object`.
2. *Обучение без учителя.* Обучить модель группировать объекты по степени похожести (найти реализацию функции `getSimilarity/getDistance`).
3. *Обучение с подкреплением.* Обучить модель действовать в некоторой неизвестной среде путем выполнения множества попыток и получения штрафов и вознаграждений.



Данные в машинном обучении – 1

Набор данных – множество векторов X (таблица с данными об объекте/объектах).

Строка – наблюдение.

Столбец – признак.

Ячейка – значение признака наблюдения.

Признак1	Признак2	Признак3	...	ПризнакN
Объект1	Значение12	Значение13	...	Значение1N
...	...	...	...	...
ОбъектM	ЗначениеM2	ЗначениеM3	...	ЗначениеMN

Вектор X (строка) – входной вектор признаков (наблюдение, значения атрибутов объекта).

Признак (столбец/ячейка) – атрибут объекта (значение некоторого свойства объекта).

Данные в машинном обучении – 2

Неструктурированные (сырые, первичные) данные – данные для анализа в из «родном» формате: текст, изображения, звук и т. д. (jpeg, doc, docx, pdf, mp3, wav, ...).

Слабоструктурированные (полуструктурированные) данные – текстовые данные с определенной структурой: логи, языки разметки, конфигурационные файлы и т. д. (xml, json, html, yaml, ...).

Структурированные (аккуратные) данные – сформированный набор данных для анализа (таблица с набором наблюдений и признаков).

Для получения структурированных данных необходимо:

1. Выполнить конструирование признаков.
2. Структурировать данные.
3. Предобработать данные.

Если данные уже были структурированы, то конструирование признаков можно выполнять после предобработки данных.

Данные в машинном обучении – 3

При решении различных задач наблюдение может быть представлено как:

1. Вектор.
2. Матрица (многомерный вектор).
3. Тензор (многомерная матрица).

Для большинства методов машинного обучения структурированные данные следует представить в виде множества векторов числовых признаков.

При решении задачи обучения с учителем целевой признак Y выбирается из доступных признаков набора данных.

Данные в машинном обучении – 4

Для решения задачи машинного обучения следует делить набор данных на выборки:




1. Обучающая выборка (70-80%). Обучение модели (подбор коэффициентов некоторой математической функции для аппроксимации).
2. *Контрольная выборка (10-15%)*. Выбор метода обучения, настройка гиперпараметров.
3. Тестовая выборка (10-15% или 20-30%). Оценка качества модели перед передачей заказчику.

При обучении нельзя использовать данные из контрольной и тестовой выборок.

Иначе модель может «запомнить» все примеры и показывать превосходное качество на тестовых данных, но показывать посредственные результаты у заказчика на реальных данных.

Конвейер машинного обучения

Конвейер (pipeline) машинного обучения – набор типовых шагов для решения задачи машинного обучения: от получения данных до внедрения модели у заказчика.



Параметры и гиперпараметры

Гиперпараметры – входные данные для конвейера машинного обучения, которые влияют на качество полученной модели.

Гиперпараметры не входят в набор данных, но включают различные параметры самого метода машинного обучения, а также параметры и типы методов предобработки и подготовки набора данных.

Параметры – параметры (коэффициенты) модели, которые «настраиваются» в процессе обучения.

Например, для линейной регрессии:


$$Y = \mathbf{w} * X + \mathbf{b}$$

Машинное обучение и глубокое обучение

Методы глубокого обучения входят в методы машинного обучения.

Однако методы глубокого обучения используют промежуточные слои, модели которых обучаются не на исходном наборе данных, а на выходных данных других слоев.

К методам глубокого обучения относятся различные архитектуры искусственных нейронных сетей.



Использование методов машинного обучения – 1

Не все задачи выгодно решать с помощью методов машинного обучения.

Когда следует использовать методы машинного обучения?

1. Задача слишком сложна для описания в виде традиционного алгоритма.
Много условий и правил или не ясно как устроен объект.
2. Условия задачи постоянно меняются.
Формат входных данных и/или требования к системе постоянно меняются.
3. Задача связана с распознаванием изображений или звуков.
4. Задача **НЕ** может быть решена традиционным способом.
5. Решение задачи экономически выгодно.

Использование методов машинного обучения – 2

Не все задачи выгодно решать с помощью методов машинного обучения.

Когда **НЕ** следует использовать методы машинного обучения?

1. Требуется объяснить как и почему система получила некоторый результат.
2. Высокая стоимость ошибки системы.
3. Ограничения по времени.
4. Можно использовать традиционные подходы к разработке с наименьшими затратами.
5. Объект слишком сложный, а данных для обучения недостаточно.

Инженерия машинного обучения

Инженерия машинного обучения (MLE, machine learning engineering) – совместное использование научных принципов, средств, технологий и методов *машинного обучения и программной инженерии* для проектирования и разработки интеллектуальных программных систем.

Поведение «обычной» программной системы детерминировано (определено, можно построить диаграмму состояний системы, блок-схемы алгоритмов).

Поведение «интеллектуальной» системы со временем может ухудшаться или становиться аномальным. Например, из-за изменений в данных или возникновения новых закономерностей, которых не существовало при обучении модели.

Жизненный цикл проекта машинного обучения

1. Понимание бизнес-цели.
Что новая система даст бизнесу?
2. Понимание цели технического проекта.
Что поступает на вход, что является целевым признаком, как оценить качество?
3. Сбор и подготовка данных (**мы находимся здесь**).
4. Конструирование признаков.
5. Обучение модели.
6. Оценка качества модели.
7. Развертывание модели.
8. Выполнение модели.
9. Мониторинг модели.
10. Сопровождение модели.

Бизнес-цель и технические цели должны совпадать.

ЖЦ позволяет возврат к любому этапу.

Ключевые показатели проекта машинного обучения

1. Последствия внедрения проекта:

- машинное обучение может заменить «сложную» часть проекта,
- «дешевая» модель с невысоким качеством дает значительные преимущества.

2. Стоимость проекта:

- сложность задачи (готовые реализации, вычислительные ресурсы, время и деньги),
- стоимость данных (сбор, разметка),
- необходимое качество модели (стоимость ошибки).

Высокие требования к качеству могут привести к использованию сложных моделей и/или необходимости больших объемов качественных данных, а также к повышению требований к вычислительным ресурсам.

Важные свойства модели машинного обучения

1. Учет бизнес-цели.
2. Учет особенностей проблемной области и данных.
3. Учет требований к качеству.
4. Экономическая выгода.
5. Полезность для пользователей.
6. Предсказуемость и воспроизводимость поведения.

Предсказуемость – получение аналогичного показателя качества на данных близких к обучающей выборке.

Воспроизводимость – получение аналогичной модели на основе тех же исходных данных: набор данных, алгоритм машинного обучения, гиперпараметры.

Члены команды

1. Аналитики, специалисты по анализу данных, data scientists (определяют цели, занимаются подготовкой данных, конструируют признаки, выбирают подходящие методы и гиперпараметры, пишут прототипы на Python).
2. *Эксперты (объясняют особенности проблемной области, помогают аналитику).*
3. Инженеры по данным (занимаются получением сырых данных).
4. Разметчики (размечают набор данных, формируют целевой Y).
5. Программисты (переписывают код аналитика с Python на более производительный язык, оптимизируют код прототипов).
6. Специалисты DevOps/MLOps (настраивают среду, CI/CD).

Причины провалов проектов

С 2017 по 2020 годы от 74% до 87% проектов в области машинного обучения и анализа данных закончились провалом и не дошли до этапа эксплуатации.

Причины:

1. Организационные:

- нехватка квалифицированных кадров (не ясно как нанимать, кандидаты прошли курсы и не имеют опыта коммерческих проектов, работали только с тестовыми данными в рамках обучения),
- отсутствие поддержки со стороны руководства (аналитики работают в условиях неопределенности и тратят много времени на эксперименты, руководители ничего не понимают, руководители не видят прогресса, научные работники не могут презентовать результат),
- разобщенность подразделений организации (данные и/или исполнители находятся в разных подразделениях),
- невыполнимые проекты (завышенные ожидания и неадекватная оценка сложности проекта).
- несогласованность бизнес-цели и цели технического проекта (аналитики не понимают бизнес-цели и решают научную задачу).

2. Технические:

- отсутствует инфраструктура для работы с данными (данные собираются вручную или скриптами, сложно воспроизвести результаты),
- проблемы разметки данных (аналитики сами размечают данные или используют аутсорсинг с низким качеством).

Сбор и подготовка данных

Задача аналитика – сформировать структурированный набор «качественных» данных пригодный для обучения качественной модели.

Свойства качества данных:

1. Доступность: авторские права, конфиденциальность, наличие персональных данных, лицензионные ограничения и т. д.
2. Объем. Оценить достаточность объема данных можно только на основе опыта предыдущих проектов. Необходимо учитывать:
 - скорость генерации данных в процессе работы над проектом,
 - минимально необходимый объем данных для достижения минимального порога качества модели,
 - наличие информативных признаков.
3. Пригодность для использования: отсутствие данных, магические числа, дубликаты, несбалансированная выборка, актуальность данных, нерепрезентативные данные (данные не покрывают большое множество вариантов), наличие искусственных зависимостей (данные собирали только по пятницам), зашумленность и смещение.
4. Понятность: необходимо понимать свойства и взаимосвязи всех признаков, чтобы признак для обучения не имел прямых зависимостей с целевым признаком (НДФЛ в задаче предсказания размера ЗП).
5. Надежность: разметка данных (эксперт или добровольцы), отсроченная метка (длительный временной промежуток между вектором признаков и целевым признаком), косвенная метка (метка «угадывается» на основе косвенных признаков).

Проблемы с данными – 1

1. Высока стоимость.

Проблема: стоимость разметки данных для новых задач.

Решение: автоматизация разметки с помощью специальных программных средств.

2. Зашумленность.

Проблема: данные повреждены (нарушено форматирование текста, размытые изображения).

Решение: методы устранения шумов. Зашумленность имеет сильное влияние на качество при небольшом количестве обучающих примеров (менее 1000), на выборках большего размера шумы обычно усредняются.

3. Смещение.

Проблема: несогласованность данных с реальными объектами и процессами.

Типы смещения:

- Смещение отбора – неудачный выбор источника данных или набора данных (данные могут содержать предвзятое мнение или ограниченный набор примеров).
- Смещение из-за отсутствия признака – отсутствие нужного признака для получения качественного предсказания (некачественные данные, изменения во времени).
- Смещение распределения – распределение наблюдений в обучающей выборке отличается от реальных данных (большинство реальных примеров вызывает ошибочную работу модели).
- Систематическая ошибка – устройство сбора данных вносит помехи в данные (пример с подводными лодками).
- Смещение разметки – разметчик халатно занимался разметкой данных (не читал весь текст, не смотрел все видео).

Решение: см. далее.

Проблемы с данными – 2

4. Низкая предсказательная способность.

Проблема: в данных недостаточно сведения для обучения (предсказать популярность видео по его названию и имени автора).

Решение: использовать косвенные источники данных для формирования дополнительных признаков.

5. Устаревшие данные.

Проблема: со временем модель «отстает» от реальности (появление новых признаков, изменение закономерностей).

Решение: добавление в набор данных новых примеров, удаление старых примеров и переобучение модели.

6. Выбросы (аномалии).

Проблема: наличие примеров, которые не похожи на другие примеры.

Решение: использовать методы нечувствительные к выбросам, удалить примеры с выбросами (не рекомендуется для небольшой выборки), на выборке большого объема выбросы обычно усредняются.

7. Просачивание данных.

Проблема: целевой признак имеет прямую зависимость от признака из данных для обучения.

Решение: анализ признаков.

Решения проблемы смещения данных

1. Смещение отбора – неудачный выбор источника данных или набора данных (данные могут содержать предвзятое мнение или ограниченный набор примеров).
Решение: Внимательно отнестись к источнику данных и провести оценку его качества, расширить набор данных новыми примерами, привлечь группу экспертов.
2. Смещение из-за отсутствия признака – отсутствие нужного признака для получения качественного предсказания (некачественные данные, изменения во времени).
Решение: формирование дополнительных признаков, в том числе на основе косвенных данных.
3. Смещение распределения – распределение наблюдений в обучающей выборке отличается от реальных данных (большинство реальных примеров вызывает ошибочную работу модели).
Решение: провести анализ распределения примеров в реальных данных и подготовить набор данных с учетом данного распределения.
4. Систематическая ошибка – устройство сбора данных вносит помехи в данные (пример с подводными лодками).
Решение: использовать различные устройства для сбора данных, сравнить результаты измерения и наблюдения для корректировки.
5. Смещение разметки – разметчик халатно занимался разметкой данных (не читал весь текст, не смотрел все видео).
Решение: оценивать работу разметчиков.
Смещение разметки приводит к смещению результатов модели, модель становится необъективной.

Свойства качественных данных

- Информативность – данные содержат достаточно примеров и признаков, которые можно использовать для обучения модели.
- Степень покрытия – учтены различные ситуации проблемной области (данные покрывают все случаи достаточным количеством наблюдений).
- Соответствие реальным данным – данные соответствуют данным, которые будут подаваться в производственной среде.
- Отсутствие смещения.
- Отсутствие обратной связи – данные не были получены с помощью самой модели.
- Согласованность меток – некоторые метки могут не соответствовать наблюдениям (человеческий фактор, изменения в проблемной области).
- Достаточность объема – данных достаточно для обобщения (выявление скрытых закономерностей).

Причины просачивания данных

1. Целевой признак имеет функциональную зависимость с признаком.
Целевой признак вычисляется на основе признака (НДФЛ и заработная плата).
2. Признак содержит целевой признак.
Признак содержит значение целевого признака (номер зачетной книжка студента содержит год поступления).
3. Признак содержит данные из будущего.
Признак содержит данные, которые были получены после определения целевого признака (предсказание наличия задолженности у студента по наличию записей о пересдачах).

Разбиение данных

Условия разбиения набора данных на выборки:

1. Разбиение применяется к сырым данным.
Помогает избежать просачивания данных.
2. Разбиение применяется после «перемешивания» данных.
3. Одинаковое распределение данных в контрольной и тестовой выборках.

Групповое просачивание во время разбиения данных – наблюдения для одного объекта попали в разные выборки.

Групповое разбиение – наблюдения для одного объекта должны попасть только в одну выборку.

Решение проблемы отсутствия значений

Решения проблемы отсутствия значений:

1. Удаление примеров с пустыми значениями (допустимо для набора данных с большим количеством наблюдений).
2. Использовать метод машинного обучения, который способен обработать пустые значения (например, деревья решений).
3. Использовать методы подстановки данных:
 - Заполнить средним значением признака (среднее по колонке).
 - Подставить магическое число (число за диапазоном доступных значений).
 - Обучить модель для предсказания пропущенного значения на основе других значений наблюдения.

Во время подстановки может возникнуть просачивание при использовании данных нескольких признаков.

Приращение (аугментация) данных

Часто приращение используют для изображений путем применения к ним различных операций: кадрирование, поворот, отражение, изменение яркости и контрастности, замена цвета, добавление шума, изменение перспективы, использование сжатия (кодирование в jpeg) и т. д. Также используется техника смешивания изображений.

Приращение также можно использовать для текстовых данных: замена слов синонимами, замена слов гиперонимами (слово с более общим значением: сапоги -> обувь), добавление шумов в векторы (embeddings), использование модели BERT, обратный перевод и т. д.

Приращение для аудиоданных включает: сдвиг данных во времени, изменение скорости, изменение высоты звука и т. д.

Несбалансированные данные

Несбалансированность данных – для некоторых меток количество наблюдений в наборе данных может иметь минимальное значение.

Данная проблема сказывается на обобщающей способности модели снижая качество.

Каждая метка должна иметь примерно одинаковое количество наблюдений.

Методы решения:

1. Выборка с избытком (oversampling). Копирование наблюдений или генерация новых наблюдений на основе существующих с помощью алгоритмов SMOTE и ADASYN (нахождение k-ближайших соседей).
2. Выборка с недостатком (undersampling). Исключение некоторых наблюдений для меток с большим количеством наблюдений. Наблюдения можно исключать случайным образом или на основе определения связей Томека для наблюдений разных меток.

Технические средства работы с данными

1. Форматы данных (CSV, XML, JSON, ARFF, LIBSVM, LIBLINEAR).
2. Уровни хранения данных (локальная файловая система, распределенная файловая система: NFS, CephFS, HDFS, хранилище данных: Amazon S3, Google Cloud Storage, СУБД, озеро данных).
3. Версионирование данных (снимок на этапе обучения, данные и код версионируются совместно, использование специализированного решения: DVC, Pachyderm).
4. Документация и метаданные.
5. Воспроизводимость. Каждый этап работы с данными должен быть реализован в виде отдельного инструмента и документирован. Не стоит использовать ручную обработку и «временные» скрипты.

Перед началом работы над задачей с помощью методов машинного обучения следует собрать много качественных данных, а не пытаться подбирать гиперпараметры модели для получения приемлемого качества.

Некачественные данные приведут к получению некачественной модели.