

Машинное обучение

Конструирование признаков

Методы искусственного интеллекта

Лекция 3

Жизненный цикл проекта машинного обучения

1. Понимание бизнес-цели.
Что новая система даст бизнесу?
2. Понимание цели технического проекта.
Что поступает на вход, что является целевым признаком, как оценить качество?
3. Сбор и подготовка данных.
4. Конструирование признаков (**мы находимся здесь**).
5. Обучение модели.
6. Оценка качества модели.
7. Развертывание модели.
8. Выполнение модели.
9. Мониторинг модели.
10. Сопровождение модели.

Пространство признаков

Признак (feature) – измеримое свойство или характеристика наблюдения.

Вектор признаков (feature vector) – n -мерный вектор числовых признаков, который представляет некоторый объект (наблюдение).


Отдельные методы машинного обучения могут обрабатывать категориальные (нечисловые) признаки, но в большинстве случаев требуется формировать вектор признаков, состоящий только из числовых значений.

Например, невозможно применить методы машинного обучения к тексту, изображению и звуку без конструирования признаков.


Признаки позволяют получить описание объектов реального мира с учетом всех необходимых для решения некоторой задачи свойств этих объектов.

Пространство признаков – 1

Вектор признаков, содержащий n признаков, формирует n -мерное пространство, в котором располагаются объекты (наблюдения) в виде точек.




Двумерное пространство признаков ($n=2$)




Трёхмерное пространство признаков ($n=3$)

Пространство признаков – 2

Для визуализации объектов в пространстве признаков при $n > 3$ используются методы понижения размерности.



Common Student Office Analysis
Enrollment Employee Theses Admin



Конструирование признаков

Конструирование признаков (feature engineering) – процесс использования знаний об особенностях решаемой задачи и предметной области для определения признаков, которые будут использованы для обучения статистической модели.

Конструирование признаков является творческим процессом, который требует от аналитика глубоких знаний предметной области и полного понимания решаемой задачи.

Конструирование признаков категориальных данных

Категориальные данные представляют нечисловые признаки.

Для векторизации категориальных данных используется унитарное кодирование (one-hot encoding) .Унитарное кодирование преобразует категориальный признак в несколько бинарных признаков.

В некоторых случаях категориальное значение заменяется на среднее значение числового признака по всем наблюдениям из данной категории.

		Name	Sex	Embarked						
PassengerId										
1		Braund, Mr. Owen Harris	male	S						
2		Cumings, Mrs. John Bradley (Florence Briggs Th...	female	C						
3		Heikkinen, Miss. Laina	female		Embarked_C	Embarked_Q	Embarked_S	Embarked_nan	Sex_female	Sex_male
4		Futrelle, Mrs. Jacques Heath (Lily May Peel)	female		0	0.0	0.0	1.0	0.0	1.0
5		Allen, Mr. William Henry	male		1	1.0	0.0	0.0	1.0	0.0
					2	0.0	0.0	1.0	0.0	0.0
					3	0.0	0.0	1.0	1.0	0.0
					4	0.0	0.0	1.0	0.0	1.0

См. пример.

Конструирование признаков числовых данных

Конструирование признаков на основе числовых данных:

- выбор признаков из набора данных;
- дискретизация признаков;
- синтез признаков на основе существующих признаков;
- масштабирование признаков.

Дискретизация признаков


Дискретизация признаков на основе распределения данных по интервалам (binning) позволяет преобразовать данные из числового представления в категориальное.

Например, для повышения предсказательной способности модели и/или повышения степени интерпретации результатов модели человеком.

Методы дискретизации признаков:

- равномерная группировка;
- группировка на основе среднего значения;
- квантильная группировка.

См. пример.



Синтез признаков

Для синтеза признаков используются различные статистические функции, а также функции агрегации и трансформации.

Синтез признаков можно осуществлять вручную или использовать средства для автоматического синтеза признаков.

Featuretools – фреймворк для автоматизации синтеза признаков.

Featuretools синтезирует признаки на основе существующих числовых признаков путем применения функций агрегации и трансформации к существующим признакам.

См. пример.

Масштабирование признаков

Масштабирование признаков позволяет привести все числовые признаки к одинаковым или очень похожим диапазонам значений либо распределениям.

По результатам многочисленных исследований масштабирование признаков позволяет получить более качественную модель за счет снижения доминирования одних признаков над другими.

Также масштабирование признаков снижает временные затраты на процесс обучения модели и уменьшает риск численного переполнения.

Методы масштабирования признаков:

- нормировка (обычно применяется для равномерного распределения);
- стандартизация (обычно применяется для нормального распределения).

Нормировка признаков

Нормировка – приведение диапазона значений признака к значениям из интервала $[0, 1]$ или $[-1, 1]$.

Для приведения значений к интервалу $[0, 1]$ используется функция:

$$\hat{x} = \frac{x - \min}{\max - \min}$$

Для приведения значений к интервалу $[-1, 1]$ используется функция:

$$\hat{x} = \frac{2 \times x - \max - \min}{\max - \min}$$

Проблема нормировки признаков

В некоторых случаях $\min$ и $\max$ могут быть выбросами, из-за чего полученный диапазон значений становится слишком мал.

Для устранения выбросов можно использовать:

- отсечение (clipping) – замена значений меньше или больше некоторого диапазона на минимальное или максимальное значение соответственно;
- винсоризацию (winsorize) – замена значений меньше или больше некоторого квартиля на значение соответствующего квартиля.

См. пример.

Стандартизация признаков

Стандартизация (нормировка по z-оценке) – масштабирование значений признака с целью приближения к стандартному нормальному распределению ($\mu = 0, \sigma = 1$).

Для стандартизации используется следующая функция:

$$\hat{x} = \frac{x - \mu}{\sigma}$$

где μ – выборочное среднее значение признака,

σ – стандартное отклонение значений признака от выборочного среднего.

См. пример.

Качество признаков

Свойства хороших признаков:

1. Высокая предсказательная способность. Признаки должны соответствовать задаче.
2. Быстрое вычисление. Не требуется вызов сторонних сервисов или выполнение сложных и долгих вычислений.
3. Надежность. Получение признака не должно зависеть от сторонних систем и данных.
4. Отсутствие корреляции. Признаки не должны иметь корреляцию между значениями.
5. Распределение значений соответствует этапу эксплуатации.
6. Цельность – не является производным от других признаков.

Отбор признаков

Отбор признаков позволяет определить только значимые для решения задачи признаки, которые позволят обучить качественную модель с высокой обобщающей способностью.

Для отбора признаков можно использовать программные средства.

Boruta – инструмент для определения значимости признаков на основе добавления новых признаков и изменения значений существующих признаков.

Также для повышения обобщающей способности модели используется регуляризация.

<https://www.kaggle.com/code/ahmettezcantekin/getting-started-with-boruta>

<https://www.kaggle.com/code/tilii7/boruta-feature-elimination>

Понижение размерности признаков

В некоторых случаях к признакам можно применять методы понижения размерности для преобразования исходного вектора признаков в вектор с меньшей длиной.

Методы понижения размерности также используются в задаче визуализации многомерных данных.

Для понижения размерности обычно используются следующие методы:

- Метод главных компонент (Principal component analysis, PCA);
- Неотрицательное матричное разложение;
- Линейный дискриминантный анализ (Linear Discriminant Analysis, LDA) и др.

Просачивание данных

При конструировании признаков возможно возникновение просачивания данных.

Для решения данной проблемы следует выполнять разбиение набора данных на выборки до конструирования признаков.

Технические средства для работы с признаками

Для хранения и версионирования сведений о признаках применяются специальные файлы схемы.

Файл схемы представляет собой машиночитаемый документ с перечнем признаков и подробной информацией о них:

- название;
- тип данных;
- количество примеров, в которых признак имеет значение;
- диапазон значений;
- среднее значение и другие статистические метрики;
- ограничения значений и др.

В некоторых организациях используются хранилища признаков, которые обновляются в оффлайн и в онлайн режимах.

Рекомендации по конструированию признаков

1. Лучше использовать большое число простых признаков. Простой признак не требует больших временных и вычислительных ресурсов для расчета значений.
2. Можно использовать существующие алгоритма для формирования признаков и их значений. В качестве признаков также могут быть использованы входные данные данного алгоритма.
3. В некоторых случаях в качестве признаков можно использовать уникальные идентификаторы объектов для локализации наблюдений (предприятие, область, регион, страна и т. д.).
4. Группировка данных при необходимости.
5. Удаление признаков при необходимости.
6. Лучше не использовать значения счетчиков в качестве признаков, так как со временем значения счетчиков могут очень сильно увеличиться.
7. Если существует необходимость, то лучше использовать отбор признаков (требования к качеству модели, ограниченные ресурсы).

Технические рекомендации

1. Тестирование кода для извлечения и конструирования признаков.
2. Версионирование кода, данных и модели.
3. Изолирование кода для выделения признаков (отдельная программа для каждого признака).
4. Поставка заказчику модели и кода для извлечения признаков.
5. Вести журнал полученных значений признаков.