

Машинное обучение

Обучение без учителя

Методы искусственного интеллекта

Лекция 5

Жизненный цикл проекта машинного обучения

1. Понимание бизнес-цели.
Что новая система даст бизнесу?
2. Понимание цели технического проекта.
Что поступает на вход, что является целевым признаком, как оценить качество?
3. Сбор и подготовка данных.
4. Конструирование признаков.
5. Обучение модели (**мы находимся здесь**).
6. Оценка качества модели.
7. Развертывание модели.
8. Выполнение модели.
9. Мониторинг модели.
10. Сопровождение модели.

Обучение без учителя

Обучение без учителя проводится на данных, в которых отсутствует целевая переменная (целевой признак).

При обучении без учителя модель обучается на самих данных.

Основной задачей обучения без учителя является нахождение множеств схожих объектов в n -мерном пространстве.

Методы обучения без учителя позволяют снизить трудоемкость анализа больших массивов данных.

В основном под обучением без учителя понимается решение задачи **кластеризации**.

Кластерный анализ

Первые публикации по кластерному анализу появились в конце 30-х гг. XX века, но активное развитие этих методов и их широкое использование началось в конце 60-х—начале 70-х гг.

Алгоритмы кластеризации позволяют выполнять многомерный анализ данных.

Методы многомерного анализа применяются в:

- психологии,
- археологии,
- биологии,
- социологии,
- экономике,
- статистике и др.

Преимущества кластеризации

1. Кластерный анализ позволяет осуществлять разбиение объектов с учетом значений различных параметров (вектору признаков).
2. Кластерный анализ НЕ накладывает ограничения на вид рассматриваемых объектов.
3. Кластерный анализ позволяет сокращать/сжимать большие объемы данных.
4. Кластерный анализ НЕ требует разметки данных.

Задача кластеризации

Задача кластеризации – разделение исследуемого множества объектов на группы «похожих» объектов (кластеры).

Кластер (cluster) – сгусток, пучок, группа.

В некоторых случаях понятия кластер и класс могут использоваться как синонимы.

Решением задачи **классификации** является отнесение каждого из объектов к одному или нескольким из **заранее определенных классов**.

При решении задачи **кластеризации** необходимо отнести каждый из объектов к одному или нескольким из **заранее неопределенных классов (кластеров)**.

Решение задачи кластеризации

Разбиение объектов по кластерам производится при одновременном их формировании.

Решением задачи кластеризации является модель, которая определяет множество обнаруженных кластеров и разбиение объектов по кластерам.

Признак принадлежности объекта кластеру может выражаться характеристическими функциями двух типов:

1. Дискретная функция: 0 (не принадлежит) или 1 (принадлежит).
2. Функция, принимающая вещественные значения. Например, может быть использован интервал $[0...1]$. Чем выше значение функции, тем больше степень принадлежности объекта кластеру.

Формальная постановка задачи кластеризации

Требования к данным:

1. Каждое наблюдение можно представить в виде числового вектора признаков.
2. Класс/классы для объектов неизвестны.

Гиперпараметры:

1. Мера сходства объектов (способ сравнения объектов).
2. Количество кластеров.
3. Алгоритм кластеризации.
4. Способ разбиения данных по кластерам.

Меры сходства объектов

Меры сходства основаны на нахождении расстояния между точками в n -мерном пространстве (расстояние между векторами).

Основные меры сходства:

1. Евклидово расстояния (используется во многих реализациях).
2. Квадрат евклидова расстояния (позволяет придать большие веса более отдаленным друг от друга объектам).
3. Расстояние по Хеммингу (схоже с евклидовым расстоянием, но с учетом уменьшения влияния отдельных больших выбросов (разностей)).
4. Расстояние Чебышева (позволяет определить объекты в качестве различных, даже если они различаются только по одной координате (признаку)).
5. Пиковое расстояние (предполагает независимость между случайными переменными) и др.

Представление результатов кластеризации

Результатом кластерного анализа является набор кластеров.

Каждый кластер содержит элементы исходного множества данных.

Полученная модель описывает множество кластеров и степень принадлежности объектов кластерам.

Обычно результаты кластеризации визуализируют.

Для визуализации результатов иерархической кластеризации используются дендрограммы.

Для визуализации результатов неиерархической кластеризации используются графики.

Для $n > 2$ применяются различные методы **понижения размерности данных**.

См. пример.

Базовые алгоритмы кластеризации

Классификация алгоритмов кластеризации:

1. Иерархические алгоритмы (см. пример).

- Агломеративные алгоритмы. Выполняются последовательным объединением исходных элементов и соответствующим уменьшением числа кластеров (построение кластеров снизу вверх).
- Дивизимные алгоритмы. Число кластеров возрастает, начиная с одного, в результате чего образуется последовательность расщепляющих групп (построение кластеров сверху вниз).

2. Неиерархические алгоритмы (см. пример).

- Четкие алгоритмы. Объект принадлежит только одному кластеру.
- Нечеткие алгоритмы. Объект принадлежит нескольким кластерам с разной степенью принадлежности (сумма всех степеней равна 1).

Неиерархические алгоритмы кластеризации

Неиерархические алгоритмы кластеризации основаны на следующих базовых понятиях:

- множество обучающих данных (предобработка, очистка, нормализация, стандартизация, конструирование признаков, векторизация);
- метрика расстояния;
- вектор центров кластеров (определяет свойства центров кластеров, центр кластера принадлежит кластеру с максимальной степенью принадлежности, центры кластеров формируются в процессе кластеризации и не содержатся в исходных данных);
- матрица разбиения по кластерам (определяет принадлежность объектов кластерам);
- целевая функция (при кластеризации производится минимизация целевой функции);
- набор ограничений (ограничения значений данных матрицы разбиения).

Методы понижения размерности

В некоторых случаях к признакам можно применять методы понижения размерности для преобразования исходного вектора признаков в вектор с меньшей длиной.

Методы понижения размерности также используются в задаче визуализации многомерных данных.

Для понижения размерности обычно используются следующие методы:

- Метод главных компонент (Principal component analysis, PCA);
- Неотрицательное матричное разложение;
- Линейный дискриминантный анализ (Linear Discriminant Analysis, LDA) и др.

См. пример.

Выбор количества кластеров

Количество кластеров оказывает существенное влияние на результат кластеризации.


Проблема выбора количества кластеров является очень сложной задачей, так как перед выполнением кластерного анализа отсутствуют сведения об анализируемых объектах.

–

Методы выбора количества кластеров:

1. Эмпирический. Количество кластеров определяется исходя из количества объектов.
2. Статистический.
3. Перебор значений с последующей оценкой качества полученных кластеров (см. пример).
4. Использование иерархических алгоритмов кластеризации (см. пример).

Базовая схема выборка количества кластеров



Оценка качества кластеризации

Основные критерии оценки качества результатов кластеризации:

1. Показатели четкости.

- Коэффициент разбиения.
- Модифицированный коэффициент разбиения.
- Индекс четкости.

2. Энтропийные критерии.

- Энтропия разбиения.
- Модифицированная энтропия.

3. Другие критерии.

- Показатель компактности и изолированности.
- Индекс эффективности.

Выводы и рекомендации

1. Задача кластеризации состоит в разделении исследуемого множества объектов на группы похожих объектов (кластеры).
2. Для определения "похожести" объектов вводится мера схожести (близости), называемая расстоянием.
3. Результаты кластеризации могут быть представлены разными способами.
4. Базовые методы кластеризации делятся на иерархические и неиерархические.
5. Наиболее популярный из неиерархических алгоритмов — алгоритм k -средних и его разновидности. Идея алгоритма заключается в определении центров k кластеров и отнесения к каждому кластеру объектов, наиболее близко находящихся к этим центрам.
6. Применение адаптивной кластеризации может помочь более эффективно решать задачу кластеризации и более взвешенно подходить к оценке результата.
7. Выбор критерия оценки качества может оказаться критичным для решения задачи.