

Машинное обучение

Обучение с подкреплением

Методы искусственного интеллекта

Лекция 6

Жизненный цикл проекта машинного обучения

1. Понимание бизнес-цели.
Что новая система даст бизнесу?
2. Понимание цели технического проекта.
Что поступает на вход, что является целевым признаком, как оценить качество?
3. Сбор и подготовка данных.
4. Конструирование признаков.
5. Обучение модели (**мы находимся здесь**).
6. Оценка качества модели.
7. Развертывание модели.
8. Выполнение модели.
9. Мониторинг модели.
10. Сопровождение модели.

Обучение с подкреплением

Обучение с подкреплением направлено на оптимизацию последовательности действий.

При обучении с подкреплением программная система пытается обучиться действовать в незнакомой среде на основе последовательного принятия решений.

Основной задачей обучения с подкреплением является поиск последовательности действий, которые позволяют достичь максимальной выгоды (награды).

Методы обучения с подкреплением позволяют решить задачу с учетом долгосрочных последствий.

Методы обучения с учителем позволяют получить оптимальное решение на текущий момент без учета влияния данного решения в долгосрочной перспективе.

История развития обучения с подкреплением

Первые результаты в области обучения с подкреплением были получены в 1952 году Дитрихом Принцем.

Принц разработал программу, которая ограничивалась решением задач на мат в два хода.

Изначально не было строгого разделения методов машинного обучения на группы.

Обучение с подкреплением применяется в:

- игры,
- робототехника,
- беспилотное вождение,
- оптимизация вычислительной инфраструктуры,
- финансовая деятельность,
- процессы в ЖКХ,
- управление движением автомобилей,
- здравоохранение
- образование и др.

Задача обучения с подкреплением

В обучении с подкреплением используется способ положительного вознаграждения за правильное действие и отрицательного за неправильное.

Алгоритм вознаграждает агента за желаемые действия и штрафует за нежелательные.

Это «мотивирует» агента на поиск максимального долгосрочного вознаграждения для достижения оптимального решения.

Данное обстоятельство не дает агенту возможности останавливаться на достигнутом.

Со временем агент учится избегать нежелательных действий и совершает только желательные.

Основные понятия

Задача обучения с подкреплением – обучение агента на поиск стратегии достижения оптимального решения в определенном контексте с учетом долгосрочной стоимости.

Агент (agent) – объект обучения. Выполняет действия в некоторой среде для получения вознаграждения.

Действие (action) – некоторое решение агента (шаг решения задачи). Действие переводит агента в некоторое состояние. Действие выбирается на основе политики.

Среда (environment) – среда, в которой объект выполняет действия для решения задачи. Среда принимает действия агента и реагирует на них.

Вознаграждение (reward) – результат выполнения действия. Формируется в процессе обратной связи со средой.

Состояние (state) – текущее положение агента в среде.

Политика (policy) – стратегия, на основе которой агент выбирает следующее действие для максимизации стоимости.

Стоимость (value) – сумма вознаграждений для определения оптимальности решения (действий агента) в долгосрочной перспективе с учетом дисконтирования (скидка, discount).

Преимущества и недостатки обучения с подкреплением

Преимущества:

1. Обучение с подкреплением похоже на машинное обучение. Но в случае обучения с подкреплением агент обучается методом проб и ошибок, используя ранее полученный опыт.
2. Обучение с подкреплением является динамическим процессом на основе проб и ошибок и не требует большого массива данных для обучения.

Недостатки:

1. Для построения качественной модели среды в некоторых случаях могут потребоваться существенные объемы данных или глубокие экспертные знания.
2. При изменении среды агент должен повторить процесс обучения, что может потребовать значительных затрат времени и вычислительных ресурсов.

Формальная постановка задачи обучения с подкреплением

Требования к данным:

1. Имеется понимание модели среды.
2. Имеется понимание возможных действий агента с учетом последствий.
3. Имеется понимание политики поведения объекта для достижения оптимального решения.

Гиперпараметры:

1. Модель среды (размер, набор состояний, препятствия и т. д.).
2. Модель агента (набор доступных действий, реакция на действия среды).
3. Методы расчета вознаграждений, штрафов, дисконтирования, стоимости.
4. Политика поведения агента.

Описание среды

Основные способы описания среды:

1. Без модели. Можно использовать для решения любых задач. Агент изучает политику в процессе взаимодействия со средой.
2. На основе модели. При наличии точной модели среды получается более качественное решение за меньшее время. Можно использовать в ограниченном множестве задач (различные игры).
3. Гибридные. Обучение особенностям поведения других агентов в процессе изучения собственной политики поведения.

Типы действий

Основные типы действий агента:

1. Дискретные действия. Выбор одного из множества действий (нажать на кнопку).
2. Непрерывные действия. Выбор степени воздействия и времени действия (как долго и с какой силой необходимо нажимать на кнопку).

Обычно алгоритмы работают только с одним типом действий.

Методы оптимизации

Основные типы методов оптимизации стоимости решения:

1. Ценностные алгоритмы. Агент пытается попробовать как можно больше действий и получить их стоимость. Далее необходимо выбрать решение с наилучшей стоимостью.
2. Алгоритмы на основе политик. Выбор действий, которые приведут к наилучшему решению.
3. Алгоритмы на основе имитации. Имитация действий эксперта.

Политика поведения объекта

Методы обновления политики:


1. Онлайн обновление политики. Агент обучается на основе новых данных и забывает их. Старые данные не используются повторно.
2. Офлайн обновление политики. Агент обучается на исторических данных для снижения стоимости обучения.
3. Гибридный метод обновления политики.

Методы выбора действий:

1. С учетом политики. Агенты учатся предсказывать награду за пребывание в определенных состояниях после выбора действий в соответствии с текущей стратегией.
2. Без учета политики. Агенты учатся предсказывать награду после выбора любого действия.

Оценка и улучшение политики

1. Агент следует политике и генерирует новые данные, описывающие состояние среды.
2. На основе новых данных агент пытается предсказать вознаграждение исходя из текущего состояния (оценка текущей политики).
3. Агент использует прогноз, чтобы решить, что делать дальше:
 - переход в состояние с большей наградой;
 - исследование среды.



Базовые алгоритмы обучения с подкреплением

1. State-Action-Reward-State-Action (SARSA). Алгоритм с учетом политики.
2. Q-Learning. Алгоритм без учета политики.
3. Deep Q-Networks. Алгоритм на основе глубоких нейронных сетей. Нейронные сети используются для исследования среды.

Выводы и рекомендации

1. Задача обучения с подкреплением состоит в выборе оптимального решения задачи на основе построения политики действий агента с наибольшей стоимостью.
2. Агент выполняет взаимодействие со средой и изменяет свое состояние через выполнение действий.
3. За каждое действие агент получает вознаграждение.
4. Существуют различные типы алгоритмов обучения с подкреплением с точки зрения организации среды, агента, методов оптимизации и изменения политики.
5. Наиболее популярный из алгоритмов обучения с подкреплением — алгоритм Q-обучения (Q-Learning).
6. При решении задачи на основе обучения с подкреплением необходимо решить каким образом можно оптимизировать алгоритм, какую форму принимают действия, требуется ли агенту формальный механизм планирования, следует ли обновлять политику в режиме онлайн и т. д.
7. При корректном определении действий и вознаграждений агентов можно решить практически любую задачу.